論 文

ボルツマンマシンを基盤とした変化検知システムの検証*

橋本 尚典[†]·松井 伸之[‡]·伊丹 哲郎[‡]·礒川悌次郎[‡]

Evaluation of Change Detection Systems Based on Boltzmann Machine*

Takanori Hashimoto[†], Nobuyuki Matsui[‡], Teturo Itami[‡] and Teijiro Isokawa[‡]

Detection of the state changes in the system, which may result in the failure of the system, would be very important in various fields of real-world engineering. We propose a novel unsupervised method for detection of changes in the framework of Energy Based Model (EBM). The proposed method incorporates the Restricted Boltzmann Machine (RBM) and Conditional Restricted Boltzmann Machine (CRBM) as EBM. The state change can be evaluated by observing the free energy in the RBM/CRBM. The proposed method is evaluated by using two sets of time series; one is a sin wave with Gaussian noises and another is the state in a CartPole system. Experimental results show that the free energy is an effective indicator for detecting the state change and that CRBM have better ability for detecting the state change than RBM.

はじめに

産業分野を問わずあらゆる分野において、故障の原因となる状態変化を精度よく検出できれば、故障を事前に防げ、故障に起因する甚大な損害を回避できる。そのため故障検出・異常検出技術の研究開発は統計的手法を中心に古くから進められてきた。しかしながら、実際の現場において異常データは希少であるため、多くの場合は正常時のデータのみを学習に用いたモデルにより変化検知がなされる。変化時のデータを学習に必要としない教師なし変化検知手法は古くから研究されている[1,2]。そして近年では、Auto Encoder 等の生成モデルを変化検知に応用する研究が様々なデータに対しておこなわれている[3,4]。

また生成モデルに関連して、画像生成等の分野において Energy Based Model (EBM) に基づいた手法が近年 見直され注目されている [5,6]. EBM では、エネルギー

Key Words: Boltzmann machine, change detection, free energy.

関数と損失関数の選択によって、様々な確率モデルを EBM の枠組みの中で表現することが可能である. その ため、EBM には様々な確率モデルを包括的に捉えるこ とができるという利点がある.

しかし、EBM を時系列データにおける変化検知に応用する研究はまだ十分になされていない。そこで、われわれはEBM として代表的なモデルであるボルツマンマシンを取り上げて変化検知手法の提案をおこなう。ボルツマンマシンとしては、入力変数についての同時確率分布を表現できる Restricted Boltzmann Machine (RBM)[8] と入力変数についての条件付き確率分布を表現できる Conditional Restricted Boltzmann Mahcine (CRBM)[9] を用いる。

まず、通常の確率モデルを変化検知に用いる際に問題となるのが、計算量的に困難な分配関数の計算である。一般に変化度として用いられる負の対数尤度比を確率モデルにおいて計算する場合、厳密に尤度を計算すると計算過程で分配関数の計算を伴うため、変化度の計算に膨大な時間を要するという問題が生じる。こうした問題に関連して、近年 Kien Do らにより EBM において定義される自由エネルギーを異常度として用いることで、分配関数の計算を必要としない、混合データに対する異常検知手法が提案された [7]. そこで、このような状況を踏まえて、自由エネルギーを変化指標の計算に用いた変化検

^{*} 原稿受付 2020年4月15日

[†] 兵庫県立大学 工学部 Faculty of Engineering, University of Hyogo; 2167 Shosha, Himeji, Hyogo 671-2280, JAPAN

[‡] 兵庫県立大学 大学院 工学研究科 Graduate School of Engineering, University of Hyogo; 2167 Shosha, Himeji, Hyogo 671-2280, JAPAN

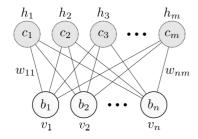


Fig. 1 Architecture of restricted Boltzmann machine

知手法を提案する.本論文中では、通常のRBM上で定義される自由エネルギーとの区別のために、CRBM上で定義される自由エネルギーを条件付き自由エネルギーとよぶ.

以下, **2.** では, 本研究で用いた EBM の必要事項について述べる. **3.** では, 変化検知手法について述べる. **4.** では, 検証実験の方法と結果について述べる. 最後に **5.** では, 本研究のまとめと結果を述べる.

2. EBM; Energy Based Model

本節では、検証実験で用いた EBM のモデル構造と、EBM 上で定義される自由エネルギーについての基本事項を述べる。まず、EBM とは変数のパターンをエネルギー関数とよばれる関数により、エネルギーに変換して表現するようなモデルの総称である。エネルギーはスカラー値であり、低いエネルギーが変数の頻出パターンに対応するように EBM は学習される [10]. 以下では、このような EBM の枠組みで構成される、RBM と CRBM について必要事項を述べる。

2.1 RBM; Restricted Boltzmann Machine

RBM[8] は、入力変数についての同時確率分布を表現できるモデルである。ここでは特に、本研究で用いた実数値を扱うことのできる、Gaussian-Bernoulli RBM について述べる。

2.1.1 モデル構造

RBM は、Fig. 1 に示すような可視層、隠れ層により構成される確率モデルであり、各層間にのみ接続をもつという接続制限をもつ。また、RBM のもつパラメータに従って、可視層は実数値 \mathbf{v} 、隠れ層は 0 か 1 の二値 \mathbf{h} を確率的にとる。以下では、可視層に関する値には i、隠れ層に関する値には i、隠れ層に関する値には i を添え字として簡潔に記述する。RBM はモデルのパラメータとして、可視層、隠れ層の各ユニットのバイアス値 b_i 、 c_j 、可視ユニット値の分散パラメータ σ_i 、可視層と隠れ層のユニット間の接続重みである $W_{i,j}$ をもつ。これらのパラメータをまとめて、 θ と表記する。以降、関数の添え字として θ が用いられた場合、その関数はパラメータ θ に従う関数であることを意味する。

上で述べたパラメータを用いて、RBM を利用するの に必要な式を定義する。まず、RBM のエネルギー関数 は次式で定義される.

$$E_{\theta}(\boldsymbol{v}, \boldsymbol{h}) = \sum_{i} \frac{(v_i - b_i)^2}{2\sigma_i^2} - \sum_{j} c_j h_j - \sum_{i} \sum_{j} v_i \frac{W_{i,j}}{\sigma_i} h_j \quad (1)$$

そして、確率分布 $\mathbb{P}_{\theta}(\mathbf{v},\mathbf{h})$ は以下のように定まる.

$$\mathbb{P}_{\theta}(\mathbf{v}, \mathbf{h}) = \frac{1}{Z_{\theta}} \exp(-E_{\theta}(\mathbf{v}, \mathbf{h}))$$
 (2)

 Z_{θ} は分配関数で次式で定義される.

$$Z_{\theta} = \int_{-\infty}^{\infty} \sum_{\tilde{\mathbf{h}}} \exp\left(-E_{\theta}\left(\mathbf{v}, \tilde{\mathbf{h}}\right)\right) d\mathbf{v}$$
 (3)

ここで、 $\hat{\mathbf{h}}$ は隠れ層が取り得るすべての二値パターンに 関する和を、 $\int_{-\infty}^{\infty} d\mathbf{v}$ は可視層が取り得るすべての実数 値パターンに関する和を表している。分配関数 Z_{θ} は、確 率密度の和が1となることを保証するための関数である。 また、分配関数の値を求める計算は指数時間を要するた め、一般に厳密な値を求めるのが困難である。

2.1.2 自由エネルギー

RBM において自由エネルギーを次式で定義する.

$$F_{\theta}(\mathbf{v}) = -\ln \sum_{\tilde{\mathbf{h}}} \exp\left(-E_{\theta}\left(\mathbf{v}, \tilde{\mathbf{h}}\right)\right) \tag{4}$$

すると、確率分布 $\mathbb{P}_{\theta}(\mathbf{v})$ を次式で表せる.

$$\mathbb{P}_{\theta}(\mathbf{v}) = \frac{1}{Z_{\theta}} \exp(-F_{\theta}(\mathbf{v})) \tag{5}$$

そして、自由エネルギーは次式に変形できるため、線形 時間で計算可能である。

$$F_{\theta}(\mathbf{v}) = \sum_{i} \frac{(v_i - b_i)^2}{2\sigma_i^2} - \sum_{i} \ln\left(1 + \exp\left(c_j + \sum_{i} v_i \frac{W_{i,j}}{\sigma_i}\right)\right)$$
(6)

2.2 CRBM; Conditional Restricted Boltzmann Machine

CRBM[9] は、入力データ間の条件付き確率分布を表現できるモデルである。時系列データ間の相関を取り扱うことができるため、時系列モデルとして用いられる。

これまでに、人体運動のモデリング [12], 音声認識 [13], 声質変換 [14] などの分野への応用が研究されてきた. ここでは、特に実数値を扱うことのできる、Gaussian-Bernoulli CRBM について述べる.

2.2.1 モデル構造

まず、Fig. 2 に検証実験で用いた CRBM の特殊な場合である出力ユニット数が1の場合におけるモデル構造を示した。このようなモデル構造の CRBM では、1次元の時系列データを扱うことができる。以降の CRBM に関連する定式化については、出力ユニット数が複数の場合に対応した一般的な場合ついて述べる。

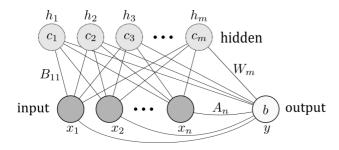


Fig. 2 Architecture of conditional restricted Boltzmann machine

CRBM は、Fig. 2のように三種の層で構成される確率モデルであり、RBM と同様の接続制限をもつ。そして、入力層の値 \mathbf{x} が与えられたもとで、出力層は実数値 \mathbf{y} 、隠れ層は 0 か 1 の二値 \mathbf{h} を確率的にとる。CRBM はモデルのパラメータとして、出力、隠れユニットのバイアス b_i 、 c_j 、出力ユニット値の分散パラメータ σ_i 、それぞれの層間の接続重みとして、 $W_{i,j}$, $A_{k,i}$, $B_{k,j}$ をもつ。

上で述べたパラメータを用いて、CRBM を利用するのに必要な式を定義する。まず、式の簡略化のために $\hat{b_i} = b_i + \sum_k A_{k,i} x_k$ 、 $\hat{c_j} = c_j + \sum_k B_{k,j} x_k$ とおくと、CRBM の条件付きエネルギー関数は次式で定義される。

$$E_{\theta}(\mathbf{y}, \mathbf{h}|\mathbf{x}) = \sum_{i} \frac{(y_{i} - \hat{b_{i}})^{2}}{2\sigma_{i}^{2}} - \sum_{j} \hat{c_{j}} h_{j} - \sum_{i} \sum_{j} y_{i} \frac{W_{i,j}}{\sigma_{i}} h_{j}$$
 (7)

そして、条件付き確率分布 $\mathbb{P}_{\theta}(\mathbf{y},\mathbf{h}|\mathbf{x})$ は次式で定まる.

$$\mathbb{P}_{\theta}(\mathbf{y}, \mathbf{h}|\mathbf{x}) = \frac{1}{Z_{\theta}(\mathbf{x})} \exp(-E_{\theta}(\mathbf{y}, \mathbf{h}|\mathbf{x}))$$
(8)

上式中の $Z_{\theta}(\mathbf{x})$ は次式で定義される分配関数である.

$$Z_{\theta}(\mathbf{x}) = \int_{-\infty}^{\infty} \sum_{\tilde{\mathbf{h}}} \exp\left(-E_{\theta}\left(\mathbf{y}, \tilde{\mathbf{h}} | \mathbf{x}\right)\right) d\mathbf{y}$$
 (9)

2.2.2 条件付き自由エネルギー

条件付き自由エネルギーを次式で定義する.

$$F_{\theta}(\mathbf{y}|\mathbf{x}) = -\ln \sum_{\tilde{\mathbf{h}}} \exp\left(-E_{\theta}\left(\mathbf{y}, \tilde{\mathbf{h}}|\mathbf{x}\right)\right)$$
(10)

すると、条件付き確率分布 $\mathbb{P}_{\theta}(\mathbf{y}|\mathbf{x})$ を次式で表せる.

$$\mathbb{P}_{\theta}(\mathbf{y}|\mathbf{x}) = \frac{1}{Z_{\theta}(\mathbf{x})} \exp(-F_{\theta}(\mathbf{y}|\mathbf{x}))$$
 (11)

自由エネルギーと同様に、条件付き自由エネルギーは次式より線形時間で計算可能である.

$$F_{\theta}(\mathbf{y}|\mathbf{x}) = \sum_{i} \frac{(y_{i} - \hat{b_{i}})^{2}}{2\sigma_{i}^{2}} - \sum_{j} \ln\left(1 + \exp\left(\hat{c_{j}} + \sum_{i} y_{i} \frac{W_{i,j}}{\sigma_{i}}\right)\right)$$
(12)

3. 変化検知手法

ここでは、時系列データにおける変化検知の問題設定、 および変化の指標である変化度の定義について述べる.

3.1 問題設定

観測値として、長さTの時系列データ $D = \{d_1, d_2, \cdots, d_T\}$ が与えられているとする。時系列データDに長さwのスライド窓を適用すると、 $\{d_1, \cdots, d_w\}, \{d_2, \cdots, d_{w+1}\}, \cdots, \{d_{T-w+1}, \cdots, d_T\}$ という長さwの部分時系列データが作成される。本研究で提案する変化検知手法では、隣り合う部分時系列データを比較することで変化を捉える。

3.2 変化度の定義

本研究では、変化の起点を捉えるための指標である変化度として、対数尤度比の大きさを用いる。1.で述べた通り、尤度の計算には分配関数の計算が必要となるため、変化度の計算過程で尤度を評価するのは計算量的に困難である。しかし、以下で述べる方法により変化度を計算することで、分配関数の計算を回避した変化度の算出が可能となる。

3.2.1 自由エネルギーによる変化度

まず、自由エネルギーを用いて変化度を計算する方法を考える。ここでは、時刻tで得られる部分時系列データを、RBM への対応を考慮して $\mathbf{v}_t = \begin{bmatrix} d_{t-w+1}, \cdots, d_{t-1}, d_t \end{bmatrix}^\mathsf{T}$ とおく。そして、時刻tにおける変化度Ch(t)を以下の式で定義する。

$$Ch(t) = \left| \ln \frac{\mathbb{P}_{\theta}(\mathbf{v}_t)}{\mathbb{P}_{\theta}(\mathbf{v}_{t-1})} \right|$$
 (13)

この変化度Ch(t)が正常時と比較して大きくなった時点を変化点と判断する.

ここで, (5) 式から,

$$\ln \frac{\mathbb{P}_{\theta}(\mathbf{v}_t)}{\mathbb{P}_{\theta}(\mathbf{v}_{t-1})} = -F_{\theta}(\mathbf{v}_t) + F_{\theta}(\mathbf{v}_{t-1}) \tag{14}$$

と式変形できるため、変化度は分配関数に関する項を打ち消したうえで、次式により計算可能である.

$$Ch(t) = |F_{\theta}(\mathbf{v}_t) - F_{\theta}(\mathbf{v}_{t-1})| \tag{15}$$

2.1.2 で述べたとおり、自由エネルギーは線形時間で計算可能であったため、上式から計算される変化度も線形時間で計算可能である.

3.2.2 条件付き自由エネルギーによる変化度

つぎに、条件付き自由エネルギーを用いた方法について説明する。条件付き自由エネルギーは時系列の相関を扱える点で、自由エネルギーと異なる。ここでは、時刻tで得られる部分時系列データを、CRBMへの対応を考慮して $\mathbf{x}_t = \begin{bmatrix} d_{t-w+1}, \cdots, d_{t-1} \end{bmatrix}^\mathsf{T}, y_t = d_t$ とおく。そして、時刻tにおける変化度Ch'(t)を以下の式で定義する。

$$Ch'(t) = \left| \ln \frac{\mathbb{P}_{\theta}(y_t | \mathbf{x}_t)}{\mathbb{P}_{\theta}(y_{t-1} | \mathbf{x}_{t-1})} \right|$$
 (16)

自由エネルギーの場合と同様に、この変化度 Ch'(t) が大きくなった時点を変化点と判断する.

また, (11) 式より,

$$\ln \frac{\mathbb{P}_{\theta}(y_{t}|\mathbf{x}_{t})}{\mathbb{P}_{\theta}(y_{t-1}|\mathbf{x}_{t-1})}$$

$$= -F_{\theta}(y_{t}|\mathbf{x}_{t}) + F_{\theta}(y_{t-1}|\mathbf{x}_{t-1}) + \ln \frac{Z_{\theta}(\mathbf{x}_{t-1})}{Z_{\theta}(\mathbf{x}_{t})} \quad (17)$$

と式変形できるが、自由エネルギーの場合と異なり、分配関数に関する項を打ち消すことができない.

そこでわれわれは、時系列データが滑らかである場合、隣合う部分時系列はほとんど等しくなると考えて、 $\mathbf{x}_t \approx \mathbf{x}_{t-1}$ から、 $Z_{\theta}(\mathbf{x}_t) \approx Z_{\theta}(\mathbf{x}_{t-1})$ が成り立つと仮定した。つまり、変化度 Ch'(t) は分配関数に関する項を無視して (17) 式から近似的に次式で計算可能であるとする.

$$Ch'(t) \approx |F_{\theta}(y_t|\mathbf{x}_t) - F_{\theta}(y_{t-1}|\mathbf{x}_{t-1})|$$
(18)

上式より計算される Ch'(t) は線形時間で計算される. この近似的に求めた異常度 Ch'(t) の有効性に関する検証を次節の実験を通じておこなう.

4. 検証実験

本節では3.において、定義した自由エネルギーの差より計算される変化度(15)式および、条件付き自由エネルギーの差から近似的に計算される変化度(18)式が、有効な指標であることを検証する.

4.1 Sin 波における検証

まずは、簡易なSin波形の時系列データを用いて変化 検知手法の検証実験をおこなう.

4.1.1 方法

はじめに、正常時の時系列データが時間 t を変数として以下の関数 f(t) で表されるとする.

$$f(t) = \sin t + noise \tag{19}$$

ここで、上式の noise 項は、平均 0、標準偏差 0.05 のガウス分布に従うノイズ値を示している。正常データとして上記の関数から、サンプリング周期 $\Delta t = 10^{-3}$ でデータを t=0 から t=50 にかけてサンプリングする。つぎに、サンプリングしたデータ系列から長さ w のスライド窓により、部分時系列データセットを作成する。そして、作成した正常時の部分時系列データセットを標準化した後にモデルに学習させ、変化検知モデルを構築する。

変化発生時のデータとして,以下の関数 g(t) から生成されるデータを用いる.

$$g(t) = \begin{cases} \sin t + noise & (t < 20) \\ \sin \left(t + \frac{\pi}{2} \right) + noise & (otherwise) \end{cases}$$
 (20)

上式の noise 項は正常時と同様に、平均 0、標準偏差 0.05 のガウス分布に従うノイズ値を示している。また式からわかるように、変化は t=20 の時点で発生する。変化発

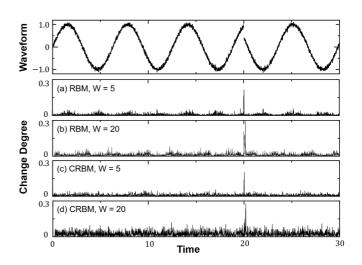


Fig. 3 Input signal (sin wave) and the degree of changes produced by the proposed method

生時の時系列データから、学習データを作成したときと同じ流れで部分時系列データを作成し、学習済みモデルを用いて変化度を逐次的に計算する.

4.1.2 モデル構成

ここでは、RBM、CRBM 共に隠れユニット数 100、学習率 0.001、ミニバッチサイズ 10 で固定して実験を試行する。また、CRBM として出力ユニット数が 1 であるモデルを用いた (Fig. 2)。そして、パラメータの学習はContrastive Divergence (CD) 法 [15] によりおこない、学習エポック数は 500 に設定する。CD 法では分散パラメータの学習が困難であるため一般に、データが標準化されているという条件下で $\sigma_i = 1$ と固定される [11]。本実験でも同様に分散パラメータを固定する。

4.1.3 考察と結果

前述の条件において、RBM と CRBM それぞれの変化 検知モデルにより変化度を計算した結果を Fig. 3 に示し た. Fig. 3 に示した変化度の遷移から、RBM、CRBM ともに Sin 波に生じた変化を検知できていることが確認 できる。また、窓サイズwの長さを 5 から 20 に変えた 際に、CRBM における変化度の正常時におけるノイズ が大きくなっていることが確認できる。これは、窓サイ ズが大きくなるほど 3.2.2 で述べた近似 $\mathbf{x}_t \approx \mathbf{x}_{t-1}$ の誤 差の蓄積が大きくなるためである。このことから、条件 付き自由エネルギーによる変化度の近似は、窓サイズwが小さい条件下において有効であるとわかる。

4.2 倒立振子における検証

本節では、倒立振子環境を用いて検証実験をおこなう. そのため、まず倒立振子とコントローラにより構成される数値実験環境を設定する.

4.2.1 環境

まず、倒立振子本体について説明する。倒立振子のシミュレーション環境として広く利用されている、OpenAI

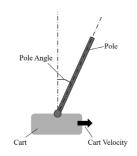


Fig. 4 A CartPole system

Gym ライブラリ¹を用いた. 倒立振子は, Fig. 4に示すように台車 (Cart) と棒 (Pole) で構成されており台車を左右に押すことにより棒を立てる. 倒立振子の状態は,台車の位置,速度,棒の角度,角速度で決まり,倒立振子への操作は 20[ms] ごとに使用環境の制約上,一定の強さで右か左に押すことが許される. 倒立振子に操作をおこなうごとに倒立振子の状態が観測される. 以下,倒立振子に対する操作の回数を Step とよぶ. また,倒立振子の初期状態においてすべての状態値がゼロとなるように設定する.

つぎに、コントローラについて説明する。コントローラは、棒の角度を倒立振子環境から受け取り、台車を押す方向を決定する。具体的に、時刻tにおける棒の角度 a_t を入力として、次式の計算値が0以上の場合は台車を右に押し、0未満の場合は左に押す。

$$K_p a_t + K_i \sum_{T=0}^t a_T + K_d (a_t - a_{t-1}) + noise$$
 (21)

上式の K_p , K_i , K_d は定数であり、それぞれ $K_p = 0.15$, $K_i = 0.02$, $K_d = 1.25$ と設定する。また noise 項は正常状態において、平均 0、標準偏差 10^{-4} のガウス分布に従うノイズ値である。そして後述の、異常状態における noise 項は、平均 0、標準偏差 10^{-2} のガウス分布に従う.

4.2.2 方法

本実験では倒立振子のコントローラに発生した変化を、棒の角度データから検知可能であるかを検証する.まず、 10^6 Step 倒立振子を操作した際の、棒の角度の時系列データを、サイズw=10のスライド窓により部分時系列に分割し、正規化したものを学習データとする.そして、テストデータとして変化発生時のデータを用意する.変化発生時のデータは、1000 Step 操作した際の棒の角度の時系列データであり、400 Step から 600 Step にかけて、(21) 式のnoise 項の標準偏差を 10^{-4} から 10^{-2} に広げることで、コントローラの操作に変化を生じさせる.このようなテストデータにおいて変化を捉えることができるかを検証する。なお、テストデータを検知モデルに与える際には、学習データの平均・分散値による正規化をおこなう.



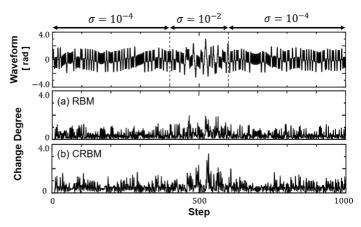


Fig. 5 Input signal (pole angle in the CartPole) and the degree of changes produced by the proposed method

4.2.3 モデル構成

Sin 波データでの実験と同様に、RBM、CRBM 共に隠れユニット数 100、学習率 0.001、ミニバッチサイズ 10 で固定して実験を試行する。また、CRBM として出力ユニット数が 1 であるモデルを用いた (Fig. 2). そして、パラメータの学習は Contrastive Divergence (CD) 法 [15] によりおこない、学習エポック数は 10^4 に設定する。このとき、Sin 波による検証実験と同様に、分散パラメータを固定する。

4.2.4 考察と結果

前述の条件において、RBM と CRBM それぞれの変化検知モデルにより、棒の角度データを入力として変化度を計算した結果を Fig. 5 に示した.

Fig. 5 から、変化の発生している 400 Step から 600 Step の間で変化度の値が大きくなっていることが確認できるため、この場合においても自由エネルギーは変化を捉える指標として有効であることがわかる。また RBM と比較して、CRBM を用いた結果では正常状態と異常状態における変化度の明暗が釈然としているため、CRBM のほうが変化検知モデルとしてより適しているとわかる結果が得られた。

5. おわりに

本論文では、EBM の枠組みで定義される RBM と CRBM による変化検知手法の提案をおこなった。通常の確率モデルを用いて変化検知をおこなう場合、一般に分配関数の計算が問題となるが、EBM において本論文で定義した自由エネルギーの差から計算される変化度を用いることで分配関数の計算を回避することが可能である。検証実験により、定義した自由エネルギーによる変化度が有効であることを示した。また、検知対象の部分時系列データの長さが短い場合に、CRBM を用いることでRBM よりも明確に変化の発生を捉えることを確認した。本研究では、基本的な EBM である RBM と CRBM を用いたが、より発展的なモデルを用いた検討および、実

環境での振動データにおける検証は今後の課題である.

参考文献

- L. Bruzzone and D. F. Prieto: Automatic analysis of the difference image for unsupervised change detection; *IEEE Transaction on Geoscience and Remote* Sensing, Vol. 38, No. 3, pp. 1171–1182 (2000)
- [2] F. Melgani, G. Moser and S. B. Serpico: Unsupervised change detection methods for remote sensing images; *Optical Engineering*, Vol. 41, No. 12 (2002)
- [3] P. Zhang, M. Gong, L. Su, J. Liu and Z. Li: Change detection based on deep feature representation and mapping transformation for multi-spatial-resolution remote sensing images; ISPRS Journal of Photogrammetry and Remote Sensing, Vol. 116, pp. 24–41 (2016)
- [4] E. Kalinicheva, J. Sublime and M. Trocan: Neural network autoencoder for change detection in satellite image time series; Proceedings of the IEEE International Conference on Electronics, pp. 641–642 (2018)
- [5] Y. Du and I. Mordatch: Implicit generation and modeling with energy-based models; arXiv preprint arXiv:1903.08689 (2019)
- [6] S. Bartunov, J. Rae, S. Osindero and T. Lillicrap: Meta-learning deep energy-based memory models; arXiv preprint arXiv:1910.02720 (2019)
- [7] K. Do, T. Tran and S. Venkatesh: Energy-based anomaly detection for mixed data; *Knowledge and Information Systems*, Vol. 57, pp. 413–435 (2018)
- [8] D. H. Ackley, G. E. Hinton and T. J. Sejnowski: A learning algorithm for Boltzmann machines; *Cognitive Science*, Vol. 9, pp. 147–169 (1985)
- [9] G. W. Taylor and G. E. Hinton: Modeling human motion using binary latent variables; Neural Information Processing Systems, Vol. 19, pp. 1354–1352, MIT Press (2007)
- [10] Y. LeCun, S. Chopra, R. Hadsell, M. A. Ranzato and F. J. Huang: A tutorial on energy-based learning; Predicting Structured Data, MIT Press (2006)
- [11] G. E. Hinton: A practical guide to training restricted Boltzmann machines; *Technical report 2010-003, Machine Learning Group, University of Toronto* (2010)
- [12] G. W. Taylor and G. E. Hinton: Factored conditional restricted Boltzmann machines for modeling motion style; Proceedings of the Annual International Conference on Machine Learning, pp. 1025–1032 (2009)
- [13] A. Mohamed and G. E. Hinton: Phone recognition using restricted Boltzmann machines; Proceedings of the IEEE International Conference on Acoustics, Speech and Signal Processing, pp. 4354–4357 (2010)
- [14] Z. Wu, E. S. Chng and H. Li: Conditional restricted

- Boltzmann machine for voice conversion; Proceedings of the IEEE China Summit and International Conference on Signal and Information Processing, pp. 104–108 (2013)
- [15] G. E. Hinton: Training products of experts by minimizing contrastive divergence; *Neural Computation*, Vol. 14, No. 8, pp. 1771–1800 (2002)

著者略歴

橋本 尚典



2021年3月兵庫県立大学工学部電気電子情報工学科卒業,同年4月兵庫県立大学大学院工学研究科電子情報工学専攻博士前期課程入学,現在に至る.統計的機械学習に関する研究に従事. IEEE 会員.

松并增之



1975年京都大学理学部卒業,1980年京都大学大学院工学研究科博士課程修了.近畿大学理工学部助手,講師,姫路工業大学 工学部助教授,1998年姫路工業大学教授を経て,2004年兵庫県立大学大学院工学研究科教授,2017年同名誉教授,特任教

授,現在に至る.機械学習,量子計算知能に関する研究に従事.工学博士.JPS,SICE の会員.

伊 哲 語



1975年京都大学理学部卒業,1980年京都大学大学院工学研究科博士課程単位取得退学,2004年大阪大学大学院博士課程修了.1982年バブコック日立株式会社勤務,2005年大阪大学特別研究員,2009年広島国際大学教授,2019年兵庫県立大学人工

知能研究教育センター リサーチ・アドミニストレータ, 現在 に至る. 全方位移動ロボット, 量子情報科学に関する研究に 従事. 博士 (工学).

議 川 悌 次 郎 (正会員)



2001年3月姫路工業大学大学院工学研究科博士後期課程単位取得退学。同年4月姫路工業大学工学部情報工学科助手,2004年4月兵庫県立大学大学院工学研究科助手,2006年10月より同准教授,現在に至る。超複素数に基づくニューラルネットワーク,

セルオートマトン,分子ロボティクスに関する研究に従事.博士(工学).IEEE,電子情報通信学会,計測自動制御学会各会員.